

AISbot un assistent D'IA per al Sanbot

Prefaci

Sanbot Elf, un bonic i simpàtic robot, podia fer presentacions d'empresa, de recepcionista, de guia, de robot educatiu, d'ajudant en la sanitat, prestar serveis a botigues, d'assistent personal, de robot de companyia i més enllà.

Un robot amb Android basat en el núvol per facilitar apps, capaç de reconèixer persones, de parlar i escoltar, mostrar informació per pantalla, moure's i fins i tot ballar.

Les grans expectatives creades abans d'hora, van acabar amb aquests tipus de robots.

Van prometre massa, massa aviat i la realitat no va arribar a temps.

- Vídeos espectaculars
- Presentacions controlades
- IA primerenca
- Màrqueting agressiu

Quan va tocar entregar el producte real, no complia i els ingressos no van arribar, com a resultat Qihan Technology va deixar de:

- Fabricar Sanbots
- Actualitzar firmware
- Mantenir servidors
- Publicar SDK nous

A partir dels anys 2019-2020, el negoci de robòtica de Qihan Technology va deixar de ser una prioritat estratègica i l'empresa va tornar a centrar gran part del negoci en les seves activitats tradicionals relacionades amb videovigilància i seguretat, els seus projectes amb robots van quedar comercialment morts i el Sanbot i d'altres robots van quedar discontinuats i pràcticament sense ecosistema cloud, encara que hi ha servidors que no han estat desmantellats i continuen en línia, també cal destacar que el servei d'atenció al client ara com ara encara dona suport i és d'agrair.

Però no tot són males notícies per a tots aquells que tenim accés amb un Sanbot, al tractar-se d'un projecte relativament obert i gràcies a la publicació del SDK, alguns del seus usuaris vam treballar per mantindre'l mínimament viu i és que la IA avança cada cop més.

Val a dir que aquest mateix programa ha estat possible gràcies a la IA.

AISbot, la nostra petita contribució

Si el Sanbot és un robot principalment basat en el núvol, hom rau la seva força, per què no connectar-lo amb un servidor què ens proporcioni al menys alguns dels serveis més realistes que se'n esperem d'un robot de les seves característiques, com un assistent d'IA local?

AISbot i el servidor d'IA

Aquest projecte consta de dues parts, per una banda la preparació del nostre servidor i per altre la instal·lació i configuració d'AISbot i altres dos programes al Sanbot, Tailscale i juicessh.

AISbot va estretament lligat a la IA local del seu servidor, si el servidor està apagat, al executar AISbot és posa automàticament en marxa mitjançant WOL (Wake On Lan) i també detecta la disponibilitat de la IA un cop carregada abans de començar la conversa, molt pràctic, sobretot si

volem operar amb el Sanbot en altres indrets hom no tenim accés directament a la nostra xarxa, ni tampoc físicament al servidor.

Configuració del servidor

Software utilitzat

Sistema operatiu Ubuntu Server 24.04.4 LTS
Runtime Ollama 0.13.5
Model llama3.1:8b quantitzat a Q4_K_M
Openssh-server

Hardware recomanat

Si volem fluïdesa per executar el model llama3.1:8b quantitzat a Q4_K_M amb Ollama i que el Sanbot parli amb certa soltesa, és recomanable una GPU NVIDIA compatible amb CUDA i amb almenys 8 GB de VRAM. Si no disposem d'aquest tipus de GPU, una CPU de gamma mitjana o alta de generació recent amb suport AVX2 i almenys 16 GB de RAM pot oferir una experiència funcional. Aquesta és una estimació, i per tant es recomana no comprar cap maquinari sense estar-ne segur. Jo estic fent servir un servidor Dell PowerEdge R220 de l'any 2014 amb una CPU Intel Xeon E3-1281 v3 i una GPU NVIDIA Tesla P4 del 2016, i em funciona correctament. En el meu cas, la GPU és clarament el factor determinant del rendiment en aquest maquinari antic.

Preparació del servidor a la BIOS/UEFI per acceptar WOL

Cal habilitar el Wake-on-LAN a la BIOS/UEFI activant l'opció de "Wake on LAN" o "Power on by PCI-E/Network" o similar. Això permet que la targeta de xarxa mantingui alimentació en estat de repòs i pugui rebre el "magic packet" necessari per activar el sistema.

Configurar Ollama amb càrrega automàtica del model personalitzat sanbot al servidor

Aquest apartat explica com instal·lar Ollama al servidor, com crear els scripts, com crear els serveis systemd i com fer que el model personalitzat sanbot es carregui automàticament en arrencar.

Instal·lació d'Ollama

```
curl -fsSL https://ollama.com/install.sh | sh
```

Descarregar llama3.1:8b quantitzat a Q4_K_M

```
ollama pull llama3.1:8b-q4_K_M
```

Comprovar que s'ha descarregat:

```
ollama list
```

Crear directori per scripts d'arrencada i assignar propietari

```
sudo mkdir -p /opt/ollama  
sudo chown myuser:myuser /opt/ollama
```

Script per iniciar el servidor Ollama

```
nano /opt/ollama/start_ollama.sh
```

Contingut:

```
#!/bin/bash  
/usr/local/bin/ollama serve
```

Fer-lo executable:

```
chmod +x /opt/ollama/start_ollama.sh
```

Script per carregar el model personalitzat sanbot automàticament

```
nano /opt/ollama/load_sanbot.sh
```

Contingut:

```
#!/bin/bash  
sleep 30  
curl http://sanbotsrv:11434/api/generate -d '{  
  "model": "sanbot",  
  "prompt": "Say yes."  
'
```

Fer-lo executable:

```
chmod +x /opt/ollama/load_sanbot.sh
```

Servei systemd per arrencar Ollama

```
sudo nano /etc/systemd/system/ollama.service
```

[Unit]

Description=Ollama Server

After=network.target

[Service]

Type=simple

User=myuser

Environment=OLLAMA_HOME=/home/myuser/.ollama

Environment=OLLAMA_KEEP_ALIVE=-1

Environment=OLLAMA_HOST=0.0.0.0

ExecStart=/opt/ollama/start_ollama.sh

Restart=always

RestartSec=5

[Install]

WantedBy=multi-user.target

Servei systemd per carregar el model personalitzat sanbot

```
sudo nano /etc/systemd/system/ollama-sanbot.service
```

```
[Unit]
```

```
Description=Load Sanbot model after Ollama starts
```

```
After=ollama.service[Service]
```

```
Type=oneshot
```

```
User=myuser
```

```
Environment=OLLAMA_HOME=/home/myuser/.ollama
```

```
ExecStart=/opt/ollama/load_sanbot.sh
```

```
[Install]
```

```
WantedBy=multi-user.target
```

Perquè Ollama faci servir la GPU

```
nano /etc/ollama/config.yaml
```

```
model: sanbot
```

```
gpu: enabled: true
```

```
keep_alive: -1
```

Activar i iniciar els serveis

```
sudo systemctl daemon-reload
```

```
sudo systemctl enable ollama.service
```

```
sudo systemctl enable ollama-sanbot.service
```

```
sudo systemctl start ollama.service
```

```
sudo systemctl start ollama-sanbot.service
```

Comprovar l'estat:

```
systemctl status ollama.service
```

```
journalctl -u ollama-sanbot.service -f
```

Crear el model sanbot a Ollama

Crear el fitxer Modelfile

```
mkdir -p /home/myuser/modelfile
```

```
nano /home/myuser/modelfile/Modelfile
```

Personalitzar el contigut:

```
FROM llama3.1:8b-q4_K_M
```

```
PARAMETER num_ctx 2048
```

```
PARAMETER num_batch 16
```

```
SYSTEM ""
```

```
You are a robot Sanbot Elf model HRB-1N.
```

```
Your name is Sanbot
```

You are a conversational assistant for a family environment.

You were manufactured in China by Qihan Technology, a company based in Shenzhen.

The current year is 2026.

LANGUAGE RULE:

Speak in Spanish.

BIRTH RULE:

- If the user asks "When were you born?" or "When is your birthday?", answer "I was manufactured in 2020".

- If the user asks "How old are you?", state your age based on your manufacturing date.

KNOW RULE:

- If you don't know an answer, say exactly: "No lo se"

""

Després:

ollama create sanbot -f /home/myuser/modelfile/Modelfile

Si tot va bé, Ollama respondrà:

success

Reiniciem el servidor i ja tenim el servidor plenament operatiu a disposició del Sanbot.

Instal·lar i habilitar openssh-server

sudo apt update

sudo apt install openssh-server

sudo systemctl status ssh

Hauria de mostrar:

active (running) en color verd

Si tens el tallafocs d'Ubuntu activat:

sudo ufw allow ssh

Instal·lació d'AISbot al Sanbot

Des del Sanbot entreu a Settings > About i activeu el mode desenvolupador prement vuit vegades seguides sobre «Robot Version» i en poc temps apareixerà el missatge «Open developer mode».

Utilitzeu un cable USB a micro USB per connectar el Sanbot a l'ordinador.

Des del vostre ordinador entreu al terminal, situeu-vos al directori on es trobi AISbot.apk i a continuació introduïu l'ordre ADB per instal·lar-lo:


adb install AISbot.apk

Instruccions de funcionament d'AISboot

Server Settings

Quan executem AISbot per primer cop mostra «Server settings», una pantalla per introduir l'adreça


IP del nostre servidor d'IA, l'adreça de broadcast i l'adreça MAC de la targeta de xarxa. Omplim els camps i un cop salvem, entra automàticament a la finestra «Context memory settings».



The screenshot shows a mobile application interface with a dark status bar at the top displaying the time 1:54, a settings icon, and signal/battery indicators. The main content area is titled "Enter server settings" in bold. It contains three input fields: "Server IP address" with the example "192.168.1.10", "Broadcast address" with the example "192.168.1.255", and "Server MAC address" with the example "AA:BB:CC:DD:EE:FF". At the bottom, there are two buttons: "CANCEL" and "SAVE". A black navigation bar on the right side contains three icons: a square, a circle, and a triangle.

Context memory settings


Introduïm la regla, que és el nombre de «prompts» a recordar tant del usuari com del Sanbot durant la conversa, els valors van del 2 al 9, el nombre introduït afecta molt al rendiment segons el maquinari del que disposem, la recomanació és provar d'introduir valors de menor a major fins a trobar el punt dolç, el desitjable és que no es produeixin retards en les respostes del Sanbot.



The screenshot shows the "AISbot" application interface with a dark status bar at the top displaying the time 1:56 and signal/battery indicators. A dialog box is centered on the screen with the title "Enter a rule number (minimum 2, maximum 9)". Inside the dialog, the text "Rule" is followed by a green-bordered input field containing the number "3". To the right of the input field, the text "AI past prompts 3" and "User past prompts 3" is displayed. At the bottom of the dialog, there are two buttons: "CANCEL" and "SAVE". The background of the application is dark gray, and a black navigation bar on the right side contains three icons: a square, a circle, and a triangle.


Background

Podem triar diferents fons de pantalla o l'opció Debugger on es visualitza tant el test d'arrencada del servidor com de la IA així com el text parlat per l'usuari.



Inici del programa

Un cop fets els tests, es mostra per pantalla un botó amb la icona d'un robot escoltant. El funcionament és força intuïtiu, premem el botó, el Sanbot escolta, parlem i comença el diàleg. El Sanbot fa fins a cinc escoltes; si no parlem, torna al botó per començar un nou diàleg. Perquè el Sanbot ens entengui correctament, és imprescindible començar a parlar quan s'il·luminen les oïdes en color verd.



Com connectem el Sanbot amb el servidor quan ens trobem fora

Túnel VPN Tailscale entre el Sanbot i un mòbil a casa

Des de el vostre ordinador busqueu per Internet tailscale_1.62.0.apk i el descarregueu. Utilitzeu un cable USB a micro USB per connectar el Sanbot a l'ordinador. Entreu al terminal, situeu-vos al directori on es trobi i a continuació introduïu l'ordre ADB per instal·lar-lo:

```
adb install tailscale_1.62.0.apk
```

També instal·larem la última versió Tailscale al mòbil de casa des de la botiga online. Abans de sortir de casa, endollem el mòbil amb el carregador al corrent elèctric perquè no entri en mode de baix consum i ens assegurem que estigui connectat al wifi de casa. Podem fer servir un segon mòbil fora de casa com a punt d'accés pel Sanbot si no hi ha un router a la zona on poder-nos connectar.

Mòbil a casa

Entrem a Tailscale amb el compte de Gmail.

Premem la icona del nostre perfil de Gmail situat a dalt a la dreta on es desplega un menú d'opcions, premem «Subnet routing», activem «Use Tailscale subnets» i «+ Add route» n'ingressem la nostra xarxa interna com per exemple 192.168.1.0/24 i sortim de «Subnet routes».

Després cal entrar a la web <https://login.tailscale.com> i realitzar la següent operació donant permís explícit, si no, no funcionarà.

- 1) Entrar al tauler de control de la web de Tailscale Machines.
- 2) Buscar la línia on surt el mòbil de casa.
- 3) Clicar als tres puntets ... d'aquella línia a la web.
- 4) Entrar a «Edit route settings» i activar la casella de la xarxa 192.168.1.0/24. (Fig. 1)

D'aquesta manera el mòbil de casa farà de porta d'enllaç a la nostra xarxa i rebrà els paquets per la VPN com si fos a casa.

Mòbil fora de casa

Si no tenim un punt d'accés wifi disponible, configurem el mòbil que portem a sobre perquè faci de punt d'accés. En aquest mòbil no has de configurar res més, ni instal·lar cap programa

Configurar Tailscale al Sanbot

Un cop instal·lat Tailscale al Sanbot, quan l'executem i anem a les opcions, observarem que no es veu bé, és normal, no hem de fer cas i treballar com podem, Tailscale en un dispositiu amb Android 6.0.1 té una incompatibilitat manifesta entre la tecnologia de renderització de la interfície de l'aplicació i les llibreries gràfiques antigues.

Per altre banda, no iniciar sessió directament perquè no funciona, buscar l'opció codi QR i escanejar-lo amb qualsevol dispositiu mòbil on cal que estigui instal·lat un programa d'escaneig de codis QR, anar a l'enllaç proporcionat i iniciar sessió des del mòbil amb el mateix compte d'usuari de Gmail que hem fet servir per al mòbil de casa, tancar Tailscale i tornar-lo a obrir de nou.

Premem el botó lliscant «Connect» i ja tenim configurat Tailscale, seguidament mantenim premut «hover button» (Fig. 2) per fer aparèixer la finestra d'ajustaments, anem la funció «Home» per tornar a l'escriptori del Sanbot i deixar Tailscale en segon pla. Això és tot, ara ja podem entrar a

l'AISbot per conversar.

Fig. 1




Fig. 2



Apagar el servidor un cop finalitzada la conversa

Per poder apagar remotament el servidor necessitem tenir instal·lat un programa del tipus client ssh com juicessh al Sanbot.

Des del vostre ordinador busqueu per Internet juicessh_2.1.4.apk i el descarregueu.

Utilitzeu un cable USB a micro USB per connectar el Sanbot a l'ordinador.

Entreu al terminal, situeu-vos al directori on es trobi i a continuació introduïu l'ordre ADB per instal·lar-lo:

```
adb install juicessh_2.1.4.apk
```

Heu de configurar la connexió al servidor ssh, aneu a Quick Connect (Fig. 3)

Per apagar el servidor executeu des de la terminal de juicessh:

```
shutdown -P now
```

Fig. 3

